

Visualisations - Projet EIDA

Benchmark de solutions – 2025

Introduction

Le projet EIDA (“Editer et analyser les Diagrammes astronomiques historiques avec l’intelligence Artificielle”) a pour but d’éditer les diagrammes de tradition ptolémaïque à l’aide des outils numériques proposés par l’application de traitement semi-automatique des sources historiques AIKON.

Dans le cadre de ce projet, nous allons être amenés à créer des visualisations de données qui seront utilisées pour le projet EIDA mais aussi pour tout autre type de projet utilisant l’application AIKON. Les données présentes sont massives et il serait bénéfique pour les chercheurs d’avoir des visualisations pour les aider dans leurs recherches et pour appuyer leurs propos dans le cadre de conférences par exemple. Néanmoins, elles pourraient s’adresser également à un public plus large. Ces visualisations seront intégrées à l’interface publique de l’application dans un nouvel onglet. Pour l’instant, nous les constituerons avec un export csv mais sur le long terme elles interrogerons la base de données pour se mettre à jour automatiquement.

Méthodologie


Les exigences liées à ces visualisations sont nombreuses. Elles doivent prendre en compte la massivité de la base de données de l’application AIKON. Il faut aussi prêter attention à ce qu’elles soient adaptables aux différents projets utilisant AIKON et pas uniquement à EIDA. Il est également nécessaire qu’elles puissent s’intégrer dans l’application qui est principalement codée en Django.

Nous allons commencer par présenter les différentes visualisations qui ont été mises de côté en les présentant et en expliquant pourquoi elles ne convenaient pas à l’application. Ensuite, nous divulguons les visualisations choisies pour intégrer l’application.

Nous évoquerons le type de visualisation, son fonctionnement, les données utilisées, la source d’inspiration, le public cible, les technologies utilisées, les points forts et les limites.

Présentation des solutions comparées

Visualisation 1 : Zoomable circle packing



Il s'agit d'une visualisation représentant des cercles emboîtés les uns dans les autres. Lorsque nous cliquons sur le premier cercle, l'image zoome sur les plus petits et ainsi de suite. Le but est d'entrer dans le corpus par le *witness* pour arriver aux différentes *regions* extraites par l'algorithme.

Cette visualisation permet de présenter le corpus. Il expose les différents *witnesses* de la base de données. S'il s'agit d'une source composite (par exemple un manuscrit dans lequel différentes oeuvres ont été copiées), il la divise ensuite en différents works. Pour finir, nous avons au sein de cette dernière catégorie les différentes régions extraites par l'application.

Cette visualisation est inspirée d'un [exemple présenté sur le site Observablehq](#). Il s'agit d'une visualisation réalisée en JavaScript avec la librairie [D3.js](#).

Le public ciblé par cette visualisation est celui des chercheurs. Cette dernière pourrait leur permettre d'accéder aux *regions* extraites par l'angle du *witness*.


Pour mettre ce dispositif en place, il est nécessaire de récolter plusieurs types de données. Les *works* du *witness* doivent si possible avoir été renseignés et les *regions* extraites par un algorithme. Au fur et à mesure que la base de données est alimentée, les nouveaux éléments s'ajoutent automatiquement.

Le principal point fort de cette visualisation est sa simplicité de réalisation et de compréhension. Il n'est donc pas nécessaire de rédiger une documentation utilisateur extrêmement poussée. En ce qui concerne le côté technique, il suffit de structurer les données nécessaires en suivant le modèle et le format requis à l'aide d'un script python et de réutiliser le

code de l'exemple. Sa simplicité permet également de s'adapter facilement à tout type de projet utilisant l'application AIKON.

Cependant, à cause de son manque de pertinence notoire, cette visualisation n'a pas été retenue pour intégrer l'interface de l'application AIKON. En effet, il est déjà possible d'accéder aux *regions* extraites par le biais de différentes rubriques comme *witness*, *work* et *series*. Elle n'apporte donc rien de nouveau à l'application.

Visualisation 2 : Carte chronologique



Il s'agit d'une carte sur laquelle sont placés les *authors*, les *witnesses* et les *works*. Elle est associée à deux frises chronologiques. La première sert à filtrer les données dans le temps en limitant la recherche à une période donnée (par exemple, choisir de n'afficher sur la carte et sur la partie inférieure de la page que les éléments concernant le Moyen Age). La deuxième frise en dessous sert à afficher les éléments d'une période plus restreinte (par exemple ceux entre 1250 et 1350) lorsque nous cliquons sur une des zones. En dessous de ces deux frises, nous retrouvons les *authors*, *witnesses* et *works* avec leurs informations respectives (date, lieu de conservation...). Si nous cliquons sur "See records" sur l'une des cases, nous arrivons sur la page dédiée à l'élément. Il est également possible de limiter la recherche à un seul *author*, *work* ou *witness* en cliquant sur le point correspondant sur la carte.

Pour concevoir cette visualisation, nous nous sommes fortement inspirés de [celle déjà existante sur l'interface DISHAS](#) pour les tables astronomiques.

En ce qui concerne l'aspect technique, cette visualisation est réalisable en JavaScript à l'aide de plusieurs bibliothèques. Tout d'abord, pour la partie carte, nous pouvons utiliser Leaflet qui permet de réaliser des cartes interactives. Pour la partie frise chronologique, la bibliothèque TimelineJS est la plus appropriée.

Contrairement à la visualisation précédente, cette visualisation vise un public plus large que celui des chercheurs. Elle s'adresse aux personnes extérieures au monde de la recherche qui voudraient s'initier à un sujet en particulier (par exemple dans le cadre du projet EIDA à l'histoire de l'astronomie et des diagrammes historiques). Nous pouvons par exemple envisager la situation suivante en ce qui concerne le projet EIDA : une personne extérieure vient visiter l'Observatoire de Paris pendant les journées du patrimoine. Elle découvre alors le projet et une fois rentrée chez elle, elle veut en apprendre davantage sur les diagrammes historiques. Elle peut alors se connecter sur le site internet du projet et visualiser les informations relatives aux manuscrits contenant des diagrammes historiques, aux lieux dans lesquels ils sont conservés, les œuvres contenues dans ces derniers... Il s'agit avant tout de représenter les métadonnées relatives au projet plutôt que des résultats concrets. La visualisation joue alors un rôle de médiation culturelle. Autre utilité de ce type de représentation : A la fin d'un projet, les chercheurs sont à la recherche d'un financement pour en démarrer un nouveau. Ils peuvent alors montrer ce type de travail pour projeter ce qu'ils pourraient faire dans le cadre d'un nouveau projet.

Pour mettre en œuvre ce type de visualisation, il faut que les chercheurs qui ajoutent leurs objets de recherche renseignent les métadonnées relatives à ces derniers de manière rigoureuse. Sans information sur les témoins, ses œuvres et ses auteurs, mettre en place ce type de représentation est impossible.

Le principal point fort de cette visualisation est son aspect ludique et simple à comprendre. Son design attrayant est également un atout pour inciter les gens à le parcourir davantage.

Cependant, nous pouvons relever de nombreux points faibles qui font que la visualisation n'a pas été retenue pour intégrer l'application. Tout d'abord, il faut prendre en compte que le public que vise l'application AIKON est avant tout des chercheurs. En réalité, les personnes extérieures au monde de la recherche sont peu à venir consulter des projets réalisés avec cette application. Ce type de visualisation ne doit donc pas être une priorité. S'il reste du temps à la fin du projet, nous pouvons peut-être envisager de la réaliser pour l'instant cela n'est

pas forcément nécessaire. De plus, la réalisation de cette visualisation serait chronophage par sa complexité technique. Il est impossible de reprendre le code de DISHAS car son interface a été codée en PHP ce qui n'est pas le cas pour des projets comme EIDA qui le sont en Python.

Visualisation 3 : Version alternative de la visualisation carte

EIDA

Admin actions

Manage documents

Computer vision tasks

Browse

User

Filtrer les résultats :
▼ Type
▼ Conservation place
▼ Work
▼ Language
Minimum date
Maximum date
Identification number



Présentation du corpus et du projet

Liste de witnesses

MS London, Wellcome Library, Persian 474

Palat. Lat. 1369 | Biblioteca Apostolica Vaticana

Persan 170 | Bibliothèque nationale de France

Cliquer sur le witness pour voir sa localisation sur la carte et afficher son contenu

EIDA

Admin actions


Manage documents

Computer vision tasks

Browse

User

Filtrer les résultats :
▼ Type
▼ Conservation place
▼ Work
▼ Language
Minimum date
Maximum date
Identification number



Présentation du corpus et du projet

Cliquer sur un témoin pour afficher les régions extraites

Lorsque l'on clique sur le marqueur d'une institution, tous les témoins conservés là-bas s'affichent sur le panneau latéral de droite

Persan 170 | Bibliothèque nationale de France

Latin 16211 | Bibliothèque nationale de France

Arabe 6686 | Bibliothèque nationale de France

EIDA

Admin actions

Manage documents

Computer vision tasks

Browse

User

Filtrer les résultats :
▼ Type
▼ Conservation place
▼ Work
▼ Language
Minimum date
Maximum date
Identification number



Présentation du corpus et du projet

Marqueur de la Bibliothèque nationale de France

Arabe 6686 | Bibliothèque nationale de France


Cette visualisation est aussi une version simplifiée de la carte chronologique. Cette dernière ne possède pas de frise chronologique et elle ne recense sur sa carte que les lieux de conservation.

Le menu à gauche permet de filtrer les lieux sur la carte selon différents critères comme le type de documents présents, l'œuvre, la date... Lorsque l'on clique sur un des marqueurs de la carte, tous les *witnesses* de la base de données présents à cet endroit s'affiche sur le côté droit. Ensuite, lorsque l'on clique sur l'un d'entre eux, toutes les *regions* extraites apparaissent.

Cette visualisation aurait été réalisée en JavaScript avec la bibliothèque Timelinejs avant d'être intégrée dans une page de l'application AIKON accessible via un onglet en haut.

Cette visualisation sous forme de carte rencontre les mêmes problèmes que la précédente. Son utilité au sein de l'application est limitée dans la mesure où la plupart des personnes qui vont l'utiliser seront des chercheurs qui veulent des outils plus sophistiqués. De plus, présenter le corpus à partir des lieux de conservation est peu pertinent car il ne s'agit pas de l'information la plus importante pour les chercheurs.

Visualisation 4 : Visualisation thématique



Capture d'écran de l'interface DISHAS (<https://dishas.obspm.fr/astronomical-navigation>)

Cette visualisation permet d'organiser les données en fonction de leur thématique. Chaque case correspond à un objet d'étude. Dans l'exemple, il s'agit des différents éléments représentés dans les diagrammes astronomiques.

Lorsque l'on clique sur l'un des éléments, les regions extraites contenant cet élément s'affichent. En cliquant sur "See records", nous arrivons sur la page du witness qui contient cette region.


Pour penser cette visualisation, nous nous sommes inspirés de [celle déjà présente sur la plateforme DISHAS](#) pour naviguer au sein des tables astronomiques.



Cette visualisation s'adresse plutôt au grand public mais elle peut intéresser également les chercheurs. Il n'est pas nécessaire d'avoir beaucoup de connaissances dans le domaine (par exemple dans le cas d'EIDA tout le monde sait ce qu'est la Lune et les différentes planètes


du système solaire) et permet de découvrir ces différents éléments au sein des sources par le biais des *regions* extraites par l'algorithme de l'application AIKON.

Néanmoins, plusieurs problèmes se posent rapidement. Tout d'abord, pour réaliser cette visualisation, il est nécessaire que les chercheurs ajoutent des tags lorsqu'ils renseignent les métadonnées de leurs witnesses et ces derniers soient normalisés (il ne faut pas que les chercheurs donnent plusieurs noms différents pour un seul et unique objet). Dans certains projets utilisant AIKON comme EIDA, cette fonctionnalité n'est pas encore utilisée donc il est impossible de mettre en place cette visualisation. Un autre problème se pose : les éléments graphiques de la visualisation ci-dessus sont adaptés au projet EIDA mais pas à d'autres projets qui ne traitent pas des sujets liés à l'astronomie. Il serait donc nécessaire de changer les éléments graphiques pour chaque projet, ce qui demanderait trop de travail pour quelque chose qui n'est pas absolument nécessaire et pertinent.

Visualisation 5 : Bart chart







Cette visualisation sert à montrer les résultats de score de similarité de l'application AIKON. Nous avons choisi le modèle de graphique *bart chart* pour représenter ses résultats.

Sur la première page, nous avons un graphe général du corpus contenant l'intégralité des *regions* extraites des *witnesses*. Il permet de classer les similarités en quatre classes et de donner leur nombre. La règle sur le côté permet de se donner une idée du nombre de similarités pour chaque catégorie. Si nous voulons connaître le nombre exact, il suffit de passer le curseur de la souris sur une des barres et il s'affichera dans une petite bulle. Il est possible de cliquer sur une des barres pour accéder à l'intégralité d'une des quatre catégories de similarité (*exact match*, *partial match*, *no match*, *semantic match*). Pour des raisons pratiques, un menu a été mis en place sur la même page en dessous pour filtrer les différents résultats. Il est possible de sélectionner uniquement un *witness* et d'afficher le graphe avec tous les types de similarités disponibles. En cliquant sur l'une des barres, toutes les similarités de la catégorie s'affichent sous la forme de *region pairs*.


Il est possible de réaliser cette visualisation en utilisant la bibliothèque JavaScript *amCharts* qui permet de réaliser des graphes *bart charts*.

Pour cette visualisation, il est nécessaire que les chercheurs annotent manuellement les résultats de l'algorithme via l'application AIKON.

Néanmoins, cette visualisation n'a pas été retenue pour plusieurs raisons. Tout d'abord, elle n'apporte rien d'utile aux chercheurs. Ces derniers n'ont pas besoin de savoir si l'algorithme a correctement fonctionné et ils n'ont besoin que des *exact matches* et peut-être des *semantic matches*. De plus, tous les résultats de scores de similarités n'ont pas été revus par les chercheurs manuellement. Cette visualisation n'est pas non plus utile aux ingénieurs qui ont

déjà leurs propres outils pour vérifier les performances des algorithmes de reconnaissance de similarités.

Visualisation 6 : Hierarchical edge bundling



Cette visualisation sert à montrer les liens de similarité entre les différentes *regions* extraites. Il s'agit d'une visualisation de type *Hierarchical Edge Bundling*.

Dans cette visualisation, les données sont organisées en *hierarchy* avec des *adjacency relations*. Il est possible de regrouper les *regions* en fonction du witness pour pouvoir comparer les relations de plusieurs d'entre eux. Les différents identifiants des *regions* sont alors organisés en cercle et reliés par des relations.

Lorsque nous passons le curseur de la souris sur une des *regions*, ses relations se colorent en rouge si l'annotation a été réalisée automatiquement et en bleu si elle a été faite à la main par un chercheur.

Nous nous sommes inspirés d'un [exemple trouvé sur Observablehq](#). Il s'agit d'une visualisation réalisée en JavaScript avec la bibliothèque [D3.js](#).

Le public ciblé par cette visualisation est celui des chercheurs.

Les données nécessaires à la réalisation de cette visualisation sont celles de la table `region_pairs`. Il faut alors garder les colonnes suivantes : `img_1`, `img_2` et `is_manual`. Il est donc nécessaire que les chercheurs annotent leurs données en amont.

Cette visualisation n'a pas été retenue pour plusieurs raisons. Tout d'abord, il y a beaucoup trop de *region pairs* par witness, ce qui risquerait de rendre la visualisation illisible puisque sa configuration en cercle est limitée dans l'espace. Mettre un trop grand nombre de *regions* et de liens risqueraient de la rendre illisible. Ensuite, il n'est pas forcément pertinent d'organiser nos données en cercle. A cause de la masse de données importantes, nous pouvons simplement comparer deux *witnesses* côte à côte et mettre leurs relations au milieu.


https://www.data-to-viz.com/graph/edge_bundling.html

Recommandations

Dans le cadre de ce projet de visualisations, nous pensons que le plus intéressant serait de se concentrer sur les similarités entre les *regions*. Nous allons donc travailler à partir de la table `region_pairs`. Nous avons imaginé deux types de visualisations.

Visualisation 1 : Bipartite graph

La visualisation de type "Bipartite graph" est une représentation visuelle des liens de similarité entre les "regions" de deux "witnesses".



Il y a les “regions” extraites de deux “witnesses” placées côte à côte et reliées entre elles. Il y a deux types de liens :

- Lien rouge : Cette similarité a été reconnue automatiquement par un algorithme.
- Lien bleu : Cette similarité a été annotée manuellement par un chercheur.

Attention : Il est possible de relier des “regions” similaires dans un même “witness”.


Au dessus des différentes “regions”, il y aura un menu déroulant qui permettra de choisir les deux witnesses à comparer. Dans cette visualisation, les données les plus importantes sont “img_1” et “img_2”. A l’intérieur, il y a le nom des fichiers des “regions” qui fonctionneront comme une “region A” et une “region B” dans notre visualisation. Le but est de faire “matcher” une “region A” avec une “region B”. Chaque “region” peut “matcher” avec plusieurs autres “regions”.

Pour réaliser cette visualisation, nous utiliserons un export de la table “region_pairs” de la base de données de VHS. Nous allons utiliser la bibliothèque JavaScript D3.js. Nous allons nous aider de ce tutoriel :

<https://observablehq.com/@nstrayer/bipartite-graph-library>.

Il faudra également ajouter les images des “regions” extraites.

Visualisation 2 : Force-directed layout



La visualisation en graphe de type “Force-directed layout” est une représentation visuelle des relations entre les différentes entités d’une base de données. Ce type de visualisation est particulièrement adaptée pour représenter les différentes “region pairs” extraites par AIKON.

Pour réaliser cette visualisation, nous ferons un export de la table `region_pairs` de la base de données du projet EIDA. Comme pour la première visualisation, le but va être de faire “match” une “region A” avec une “region B”. Une “region A” peut également “match” avec une “region C” en plus de la “region B”. Nous allons utiliser Gephi, un logiciel simple d’utilisation à utiliser en local qui permet de réaliser des graphes relationnels sans coder.

Pour utiliser Gephi, nous devons renommer certaines colonnes en “source” (`img_1`) et “target” (`img_2`) pour établir les liens entre les labels.

Les graphes réalisés avec Gephi sont composés de trois éléments :

- Les nœuds : Ce sont les entités de la base de données. Dans notre cas, il s’agit des différentes “regions” extraites.
- Les arêtes : Ce sont les relations ou connexions entre les nœuds.
- Les labels : Ce sont les noms ou étiquettes rattachés à un noeud ou à une arête pour le rendre lisible ou identifiable dans le graphe :
 - Les labels de noeuds : les noms ou identifiants des entités
 - Les labels des arêtes : les types de relation entre les noeuds

Dans notre visualisation, les labels de noeuds sont les noms des fichiers images des “regions” extraites. En ce qui concerne les labels des arêtes, nous pouvons intégrer le score de similarité des différentes “region pairs”.