

Visualisations - Projet EIDA

Cahier des charges – 2025

Introduction

Le projet [EIDA](#) (“Editer et analyser les Diagrammes astronomiques historiques avec l’intelligence Artificielle”), porté par le laboratoire LTE (Laboratoire Temps Espace), vise à étudier les diagrammes astronomiques de tradition ptoléméenne en prolongeant les travaux du projet [DISHAS](#) (“Digital Information System for the History of Astral Sciences”) grâce à la mutualisation de données et d’outils.

Il s’appuie sur la plateforme [AIKON](#) qui permet d’analyser automatiquement des sources numérisées grâce à des algorithmes de vision artificielle. Cette dernière peut être adaptée à d’autres projets similaires comme [VHS](#) (“Computer vision and Historical Analysis of Scientific Illustration Circulation”) ou [High Vision](#) par exemple.

Dans l’application AIKON, plusieurs types de données sont ajoutées et produites. Tout d’abord, les chercheurs ajoutent des “witnesses” (des objets physiques ou des sources primaires conservés dans une institution). Ils doivent alors remplir des métadonnées pour identifier le “witness” (type, identification number, conservation place...). Ensuite, il est nécessaire d’ajouter la numérisation du “witness” sous la forme d’une image, d’un pdf ou d’un manifeste. Pour finir, il faut décrire les différents contenus du “witness” (par exemple dans le cas d’un manuscrit composite, il peut y avoir plusieurs œuvres différentes). Dans cette application, il est aussi possible de créer des “series” : il s’agit d’un ensemble avec ses propres métadonnées regroupant des “witnesses” ayant une cohérence commune (par exemple plusieurs témoins d’une même édition conservés au même endroit). Les “document sets” sont des regroupements de “witnesses” personnalisés par l’utilisateur dans le cadre de ses recherches. Pour finir, les “works” représentent des œuvres intellectuelles et leurs métadonnées. Il est possible de leur rattacher des “witnesses” qui contiennent ces œuvres (ex : tous les témoins contenant l’Almageste de Ptolémée).

Une fois la numérisation du “witness” intégrée à la base de données, ce dernier va subir différents traitements qui vont produire de nouvelles données.

Tout d’abord, il y a l’ “image regions extraction”. Elle peut se faire de manière manuelle avec Mirador Viewer mais il s’agit d’une tâche chronophage. AIKON possède une fonctionnalité qui permet d’extraire automatiquement des régions (par exemple dans le cadre du projet EIDA il existe un algorithme pour extraire tous les diagrammes astronomiques mais ce procédé peut être adapté à d’autres types d’image). Par la suite ces données peuvent être visualisées par “witness” ou par “page”.

Les régions extraites peuvent être exportées par les chercheurs. Néanmoins, l'application AIKON possède plusieurs types de traitements pouvant être appliqués aux régions.

Il existe notamment des algorithmes permettant de calculer le “similarity score” entre différentes “regions” extraites. Cette fonctionnalité produit des “region pairs”, c'est-à-dire deux “regions” qui sont plus ou moins similaires en fonction de leur score de similarité. Une fois l'algorithme appliqué aux données, le chercheur peut annoter manuellement les résultats. Pour chaque “region pair”, il peut choisir entre “exact match”, “partial match”, “semantic match”, “no match” et “user match”. Cependant, dans l'état actuel du projet, les annotations manuelles des chercheurs restent minoritaires.

Objectifs et besoins

Nous allons réaliser des visualisations à inclure dans l'application AIKON. Pour mener à bien cette mission, il est important de réfléchir aux objectifs et aux besoins auxquels elle répond.

Notre principal objectif est de visualiser les résultats des traitements réalisés par l'application AIKON sur un corpus donné. Nous avons fait le choix de nous concentrer sur la reconnaissance automatique des similarités entre les différentes “regions” extraites.

Lorsque nous dialoguons avec les chercheurs, nous observons que la visualisation de leurs données est essentielle dans leur travail de recherche. Beaucoup d'entre eux réalisent leurs propres visualisations manuellement sur leur ordinateur pour mieux s'y retrouver et pour montrer les résultats de leurs recherches au public (pendant des colloques, conférences, cours...). La plupart du temps, ils se tournent vers un schéma en arborescence pour visualiser l'évolution des objets d'étude en fonction du temps et de l'espace.

Réaliser des outils de visualisation qui seraient directement intégrés à l'application AIKON leur faciliterait grandement la vie. Cela permettrait de mettre à jour automatiquement les résultats. Ils gagneraient du temps puisqu'ils n'auraient plus à manipuler des éditeurs d'images comme Photoshop ou Figma par exemple. Ces outils permettraient également de visualiser une masse de données importante (des milliers de “regions” par exemple), ce qui ne serait pas possible de faire manuellement.

Ce type d'outils incite les chercheurs au travail collaboratif. En effet, ces derniers auront accès à la fois à leurs données mais également à celles des autres qui seront stockées dans la base de données de l'application.

Un autre objectif serait de créer des visualisations adaptables à tous les projets utilisant l'application AIKON et pas seulement à EIDA. Il faut donc faire attention à ne pas réaliser des visualisations uniquement adaptées pour la question des diagrammes astronomiques.

Une autre question se pose également : celle du design. Il faut que les visualisations soient attrayantes visuellement mais aussi qu'elles se fondent dans l'écosystème de l'interface utilisateur.

Données

Nous avons fait le choix de réaliser deux visualisations différentes pour montrer les liens de similarités entre les différentes "regions".

Dans les deux cas, nous allons nous concentrer sur la table "region_pairs". Lorsque les visualisations seront déployées dans l'application, elles interagiront avec la base de données mais pour faire notre preuve de concept nous allons réaliser un export de cette table en csv.

	A	B	C	D	E	F	G	H	I	J	K	L
1	id	img_1	img_2	regions_id_1	regions_id_2	category	category_x	created_at	updated_at	is_manual	score	similarity_type
2	1wt11_man191_0560_1172_1410_429_533.jpg	wt163_img163_061_1249_1715_283_332.jpg	163	188	NULL	0	0	2024-04-18 15:02:47 929644+00	2024-04-18 15:02:59 388669+00	False	NULL	1
3	2wt11_man191_0560_1172_1410_429_533.jpg	wt206_man335_0124_457_1606_412_511.jpg	188	216	2	0	0	2024-04-23 08:12:39 188659+00	2024-04-23 08:12:39 237295+00	False	NULL	1
4	3wt11_man191_0560_1172_1410_429_533.jpg	wt206_man335_0402_1189_358_391_473.jpg	188	216	1	0	0	2024-04-23 08:12:46 359862+00	2024-04-23 08:12:46 439726+00	False	NULL	1
5	4wt11_man191_0579_264_1097_467_569.jpg	wt201_man213_0056_109_551_434_481.jpg	188	208	NULL	0	0	2024-04-23 08:13:09 611264+00	2024-04-23 08:13:10 746924+00	False	NULL	1
6	5wt11_man191_0664_472_905_489_600.jpg	wt40_img40_0103_1093_289_660_790.jpg	188	40	NULL	0	0	2024-04-23 08:13:19 344236+00	2024-04-23 08:13:25 866735+00	False	NULL	1
7	6wt32_img32_0114_125_242_459_634.jpg	wt34_img34_0118_1763_1836_3675_3884.jpg	32	34	4	0	0	2024-04-26 10:31:43 942884+00	2024-04-26 10:31:43 979684+00	False	NULL	1
8	7wt32_img32_0114_125_242_459_634.jpg	wt147_img147_0205_209_244_1052_1349.jpg	147	32	4	0	0	2024-04-26 10:31:48 992251+00	2024-04-26 10:31:49 036081+00	False	NULL	1
9	8wt32_img32_0114_125_242_459_634.jpg	wt147_img147_0214_453_955_708_620.jpg	147	32	4	0	0	2024-04-26 10:31:50 736316+00	2024-04-26 10:31:50 750631+00	False	NULL	1
10	9wt32_img32_0114_125_242_459_634.jpg	wt34_img34_0139_321_5010_3606_2477.jpg	32	34	4	0	0	2024-04-26 10:31:52 94523+00	2024-04-26 10:31:52 979871+00	False	NULL	1
11	10wt32_img32_0114_125_242_459_634.jpg	wt34_img34_0049_283_1309_3824_4889.jpg	32	34	4	0	0	2024-04-26 10:31:59 510784+00	2024-04-26 10:31:59 563555+00	False	NULL	1
12	11wt32_img32_0114_125_242_459_634.jpg	wt34_img34_0124_3006_1351_2312_2310.jpg	32	34	4	0	0	2024-04-26 10:32:00 609474+00	2024-04-26 10:32:00 654051+00	False	NULL	1
13	12wt32_img32_0114_125_242_459_634.jpg	wt34_img34_0124_3008_3737_2311_2338.jpg	32	34	4	0	0	2024-04-26 10:32:02 10898+00	2024-04-26 10:32:02 123272+00	False	NULL	1
14	13wt32_img32_0114_125_242_459_634.jpg	wt147_img147_0215_291_148_781_621.jpg	147	32	4	0	0	2024-04-26 10:32:04 921502+00	2024-04-26 10:32:05 489971+00	False	NULL	1
15	14wt32_img32_0114_125_242_459_634.jpg	wt147_img147_0195_278_1062_877_683.jpg	147	32	4	0	0	2024-04-26 10:32:07 623322+00	2024-04-26 10:32:07 640019+00	False	NULL	1
16	15wt32_img32_0114_125_242_459_634.jpg	wt147_img147_0252_3763_2036_272_185.jpg	147	32	4	0	0	2024-04-26 10:32:09 304252+00	2024-04-26 10:32:09 338596+00	False	NULL	1
17	16wt32_img32_0118_80_273_707_781.jpg	wt147_img147_0205_209_244_1052_1349.jpg	147	32	4	0	0	2024-04-26 10:32:37 62634+00	2024-04-26 10:32:37 652404+00	False	NULL	1
18	17wt32_img32_0118_80_273_707_781.jpg	wt34_img34_0118_1763_1836_3675_3884.jpg	32	34	4	0	0	2024-04-26 10:32:39 121596+00	2024-04-26 10:32:39 138156+00	False	NULL	1
19	18wt32_img32_0118_80_273_707_781.jpg	wt147_img147_0214_453_955_708_620.jpg	147	32	4	0	0	2024-04-26 10:32:40 462854+00	2024-04-26 10:32:40 485915+00	False	NULL	1
20	19wt32_img32_0118_80_273_707_781.jpg	wt34_img34_0049_283_1309_3824_4889.jpg	32	34	4	0	0	2024-04-26 10:32:41 806169+00	2024-04-26 10:32:41 821536+00	False	NULL	1
21	20wt32_img32_0118_80_273_707_781.jpg	wt34_img34_0124_3006_1351_2312_2310.jpg	32	34	4	0	0	2024-04-26 10:32:46 546035+00	2024-04-26 10:32:46 592818+00	False	NULL	1
22	21wt32_img32_0118_80_273_707_781.jpg	wt34_img34_0139_321_5010_3606_2477.jpg	32	34	4	0	0	2024-04-26 10:32:50 537383+00	2024-04-26 10:32:50 553016+00	False	NULL	1
23	22wt32_img32_0118_80_273_707_781.jpg	wt147_img147_0215_291_148_781_621.jpg	147	32	4	0	0	2024-04-26 10:32:54 91964+00	2024-04-26 10:32:54 953269+00	False	NULL	1
24	23wt32_img32_0118_80_273_707_781.jpg	wt34_img34_0124_3008_3737_2311_2338.jpg	32	34	4	0	0	2024-04-26 10:32:56 129643+00	2024-04-26 10:32:56 169689+00	False	NULL	1
25	24wt32_img32_0118_80_273_707_781.jpg	wt147_img147_0195_278_1062_877_683.jpg	147	32	4	0	0	2024-04-26 10:32:57 469787+00	2024-04-26 10:32:57 504594+00	False	NULL	1
26	25wt32_img32_0118_80_273_707_781.jpg	wt34_img34_0141_107_3120_4236_3420.jpg	32	34	4	0	0	2024-04-26 10:32:59 166307+00	2024-04-26 10:32:59 179621+00	False	NULL	1
27	26wt32_img32_0114_90_1297_809_830.jpg	wt147_img147_0215_291_148_781_621.jpg	147	32	4	0	0	2024-04-26 10:33:07 704772+00	2024-04-26 10:33:07 737971+00	False	NULL	1
28	27wt32_img32_0114_90_1297_809_830.jpg	wt34_img34_0124_3008_3737_2311_2338.jpg	32	34	4	0	0	2024-04-26 10:33:09 099134+00	2024-04-26 10:33:09 116345+00	False	NULL	1

Capture d'écran de l'export en format csv ouvert sur LibreOffice Calc

Pour nettoyer notre fichier csv en ne gardant que les données dont nous avons besoin, nous utiliserons un script python avec la librairie Pandas. En effet, il est nécessaire de supprimer certaines colonnes (comme region_id_1, region_id_2, updated_at et created_at). Les colonnes restantes sont les suivantes :


- id
- img_1
- img_2
- is_manual
- score
- similarity_type

Pour finir, nous sélectionnerons un échantillon de données (deux ou plusieurs "witnesses") car la base de données est trop lourde pour intégrer toutes les données à nos visualisations.

Fonctionnalités

Visualisation de type “Bipartite graph”

La visualisation de type “Bipartite graph” est une représentation visuelle des liens de similarité entre les “regions” de deux “witnesses”.



Il y a les “regions” extraites de deux “witnesses” placées côte à côte et reliées entre elles. Il y a deux types de liens :

- Lien rouge : Cette similarité a été reconnue automatiquement par un algorithme.
- Lien bleu : Cette similarité a été annotée manuellement par un chercheur.

Attention : Il est possible de relier des “regions” similaires dans un même “witness”.

Au dessus des différentes “regions”, il y aura un menu déroulant qui permettra de choisir les deux witnesses à comparer. Dans cette visualisation, les données les plus importantes sont “img_1” et “img_2”. A l’intérieur, il y a le nom des fichiers des “regions” qui fonctionneront comme une “region A” et une “region B” dans notre visualisation. Le but est de faire “matcher” une “region A” avec une “region B”. Chaque “region” peut “matcher” avec plusieurs autres “regions”.

Pour réaliser cette visualisation, nous utiliserons un export de la table “region_pairs” de la base de données de VHS. Nous allons utiliser la bibliothèque JavaScript D3.js. Nous allons nous aider de ce tutoriel :

<https://observablehq.com/@nstrayer/bipartite-graph-library>.

Il faudra également ajouter les images des “regions” extraites.

Visualisation de type “Force-directed layout”

La visualisation en graphe de type “Force-directed layout” est une représentation visuelle des relations entre les différentes entités d’une base de données. Ce type de visualisation est particulièrement adaptée pour représenter les différentes “region pairs” extraites par AIKON.


Pour réaliser cette visualisation, nous ferons un export de la table region_pairs de la base de données du projet EIDA. Comme pour la première visualisation, le but va être de faire “matcher” une “region A” avec une “region B”. Une “region A” peut également “matcher” avec une “region C” en plus de la “region B”. Nous allons utiliser Gephi, un logiciel simple d’utilisation à utiliser en local qui permet de réaliser des graphes relationnels sans coder.

Pour utiliser Gephi, nous devons renommer certaines colonnes en “source” (img_1) et “target” (img_2) pour établir les liens entre les labels.


Les graphes réalisés avec Gephi sont composés de trois éléments :


- Les nœuds : Ce sont les entités de la base de données. Dans notre cas, il s’agit des différentes “regions” extraites.
- Les arêtes : Ce sont les relations ou connexions entre les nœuds.
- Les labels : Ce sont les noms ou étiquettes rattachés à un noeud ou à une arête pour le rendre lisible ou identifiable dans le graphe :
 - Les labels de noeuds : les noms ou identifiants des entités
 - Les labels des arêtes : les types de relation entre les noeuds


Dans notre visualisation, les labels de noeuds sont les noms des fichiers images des “regions” extraites. En ce qui concerne les labels des arêtes, nous pouvons intégrer le score de similarité des différentes “region pairs”.




Une fois le fichier csv inséré dans Gephi, nous pouvons choisir un type de spatialisation et personnaliser chaque élément du graphe (couleur des liens, espacement des nœuds...). Ici, nous avons choisi la spatialisation “Fruchterman Reingold” qui permet d’avoir un résultat plutôt aéré. Lorsque nous passons le curseur de la souris sur un des nœuds, seuls les nœuds et les arêtes de ses similarités s’affichent. Par la suite, nous pourrions changer la couleur des liens et ajouter dans les nœuds les images des “regions” (dans notre cas des diagrammes astronomiques).








Il est également possible d'exporter notre visualisation en format code à l'aide du module [Sigma.js](#). Cela génère un dossier "network" avec un fichier "index.html" qui peut être ouvert dans un navigateur en utilisant Live Server. Nous avons également, des fichiers css, des images, des fichiers JavaScript ainsi que les données en format JSON (data.json). Il est donc possible de personnaliser son graphe avec des fonctionnalités qui n'étaient pas possible directement dans Gephi.





Contraintes techniques

Dans le cadre de ce projet, nous allons rencontrer certaines contraintes techniques :

- D'abord, nous sommes limités par *le temps*. En effet, ces deux visualisations doivent être réalisées dans le cadre d'un stage de fin d'études de master de 4 mois.
- Ensuite, nous n'aurons pas accès à la base de données entière de l'application pour réaliser ces deux visualisations. Nous ne possédons qu'un export csv de la table "region_pairs". Il n'est donc pas possible d'intégrer les métadonnées des witnesses (id, conservation place, work, etc...) car elles ne sont pas présentes dans cette table.
- Pour finir, ces visualisations doivent être adaptées à tous les types de projets pouvant utiliser AIKON pour traiter leurs données. Même si nous nous appuyons sur les données de EIDA et de VHS, il faut penser au fait qu'elles seront utilisées pour d'autres projets qui n'auront peut-être rien à voir avec le domaine de l'histoire des sciences.

Design et intégration



Pour intégrer les visualisations à l'application AIKON, nous allons créer un nouvel onglet "Similarity". A l'intérieur de ce dernier, il y aura une page pour chaque visualisation.

Livrables

- Cahier des charges
- Benchmark des solutions opérationnelles
- Documentation sur les réalisations (code, pages wiki...)
- Présentation des résultats obtenus lors d'un DH Seminar
- Visualisations pour la plateforme EIDA

Ressources

Visualisations :

- Lagnel Jean-Marie. *Manuel de Datavisualisation*. 2e édition enrichie. ed. Malakoff: Dunod, 2021.

Pandas :

- Tutoriel Python pandas : Le guide ultime pour les débutants : <https://www.datacamp.com/fr/tutorial/pandas>
- 10 minutes to pandas : https://pandas.pydata.org/docs/user_guide/10min.html
- Introduction à Pandas : <https://www.python-simple.com/python-pandas/panda-intro.php>

D3.js :

- Site officiel de la librairie D3.js : <https://d3js.org/>

- Documentation officielle : <https://d3js.org/getting-started>
- Observable “Bipartite Graph Library” (Nick Strayer) :
<https://observablehq.com/@nstrayer/bipartite-graph-library>

Gephi :

- Gephi Tutorial Visualization :
<https://gephi.org/tutorials/gephi-tutorial-visualization.pdf>
- Gephi Tutorial for Graph/Network Visualization :
<https://github.com/franktakes/gephi-tutorial>
- Gephi tutoriel : <https://datahist.hypotheses.org/13>